Politécnico Castelo Branco
Escola Superior de Tecnologia

Escola Superior de Tecnologia
Mestrado em Engenharia Informática - Área de Especialização em Desenvolvimento de Software e Sistemas Interativos
2º Semestre do 1º Ano

Unidade Curricular: Business Intelligence

Docente: Luís Barata
Ano Letivo 2025/26

Projeto 2 – Databricks

O projeto consistirá na utilização da plataforma Azure Databricks para ingestão, transformação e análise de dados, podendo ser usado o mesmo dataset utilizado no Projeto 1 – Neo4j (a partir de ficheiros CSV ou outra fonte original), com o objetivo de comparar a componente analítica entre uma base de dados grafo e uma arquitetura de data lakehouse.

Os estudantes deverão explorar as funcionalidades de Notebooks, tabelas Delta e Dashboards (AI/BI dashboards) do Azure Databricks, podendo ainda, de forma opcional, usar as capacidades de Machine Learning integradas (MLflow / Databricks Machine Learning) para criar e avaliar modelos preditivos simples sobre o mesmo conjunto de dados.

Etapas do projeto

1. **Preparação do ambiente Azure Databricks**
    - Criar um workspace Azure Databricks numa subscrição disponibilizada para a UC, configurando um cluster ou SQL warehouse adequado ao volume de dados.
    - Garantir o acesso ao armazenamento de dados (por exemplo, Azure Data Lake Storage Gen2 ou Blob Storage) para leitura/escrita de ficheiros CSV e tabelas Delta.
2. **Ingestão e modelação dos dados**
    - Reutilizar, caso faça sentido, o dataset do Projeto 1 – Neo4j, importando-o para o Azure Databricks a partir de ficheiros CSV ou da fonte original.
    - Criar tabelas em formato Delta Lake a partir dos dados ingeridos, garantindo um esquema bem definido e documentando decisões de tipagem, normalização e tratamento de valores em falta ou inconsistentes.
3. **Transformações e consultas analíticas**
    - Implementar, em notebooks Databricks (SQL, PySpark ou Scala), um conjunto de transformações que preparem os dados para análise (limpeza, derivação de colunas, agregações, joins, etc.).
    - Definir e executar consultas analíticas que permitam responder a questões de negócio relevantes para o dataset, incluindo métricas agregadas, rankings e indicadores comparáveis com os produzidos no Projeto 1 (quando aplicável).

4. **Criação de dashboards em Azure Databricks**
    - Utilizar os AI/BI Dashboards do Azure Databricks para criar páginas de relatório com visualizações apropriadas (gráficos de barras, linhas, mapas, tabelas resumo, etc.), ligadas às tabelas Delta ou vistas definidas.
    - Explorar, se possível, as funcionalidades de assistência por IA na criação de dashboards (por exemplo, geração de visualizações com linguagem natural) e documentar as vantagens e limitações observadas.
5. **Exploração opcional de Machine Learning**
    - Para grupos que pretendam ir mais longe, utilizar os recursos de Machine Learning do Azure Databricks (por exemplo, MLflow e Databricks Machine Learning) para treinar um modelo simples (classificação ou regressão) sobre o dataset, documentando: escolha de variáveis, divisão treino/teste, métrica de avaliação e interpretação básica dos resultados.
    - Se for usado MLflow, ilustrar a forma como os registos de experiências (runs, métricas e parâmetros) podem ser consultados e, se desejado, usados em dashboards para monitorização de modelos.
6. **Comparação com o Projeto 1 (caso tenham utilizado o mesmo Dataset)**
    - Discutir semelhanças e diferenças entre a análise efetuada em Neo4j AuraDB e em Azure Databricks, em termos de: facilidade de ingestão, flexibilidade de modelação, expressividade das consultas, capacidades de visualização e potencial para integração com ML.
    - Explicitar em que situações o modelo grafo se revelou mais vantajoso e em que cenários a abordagem lakehouse / Databricks foi mais adequada.

O trabalho será realizado em grupos de até 5 alunos, podendo ser alvo de uma apresentação.

Data de Entrega: **05/06/2026 – 23:55** (via moodle)

Elementos a Entregar:

1. Origem do Dataset
2. Breve documento contendo:
    a. Documentação do processo de ingestão, tratamento e modelação dos dados em Azure Databricks (incluindo criação de tabelas Delta).
    b. Listagem e explicação das principais queries e transformações usadas para obter métricas e vistas analíticas.
    c. Descrição das visualizações criadas nos dashboards Databricks, com os principais insights identificados e respetiva interpretação de negócio.

d. (Opcional) Descrição do(s) modelo(s) de Machine Learning desenvolvido(s), incluindo objetivo, algoritmo escolhido, métricas de desempenho e principais conclusões.
e. Secção de comparação crítica com o Projeto 1 – Neo4j, evidenciando os contributos de cada tecnologia para um processo de Business Intelligence completo.

Bom Trabalho!